# Modèle de machine learning avec sklearn

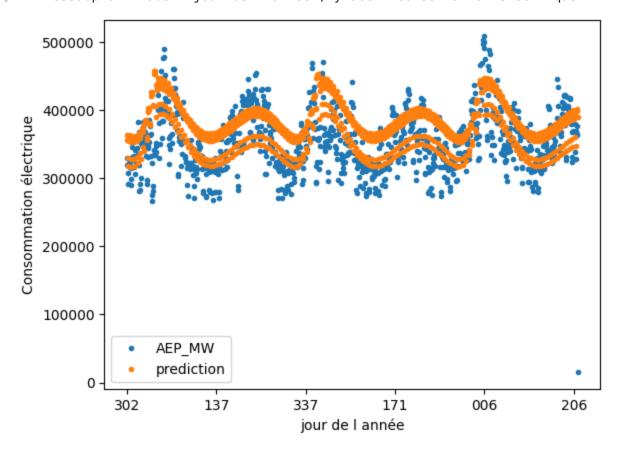
Importation des librairies nécéssaires et implémentation du dataset

```
In [1]: from sklearn.linear model import LinearRegression
        from sklearn.preprocessing import PolynomialFeatures
        from sklearn.preprocessing import StandardScaler
        from sklearn.pipeline import Pipeline
        from sklearn.metrics import mean squared error, mean absolute error
        import pandas as pd
        import numpy as np
        dataset = pd.read csv('AEP hourly.csv')
        dataset = dataset.set index('Datetime')
        dataset.index = pd.to datetime(dataset.index)
In [2]: #split train et test
        daily groups = dataset.resample('D')
        daily data = daily groups.sum()
        daily data["day of week"] = daily data.index.isocalendar().day
        daily data["day of year"] = daily data.index.strftime("%j")
        nb lines = daily data.shape[0]
        train = daily data.iloc[:int(nb lines*0.8)]
        test = daily data.iloc[int(nb lines*0.8)+1:]
```

## On réalise un modèle polynomial

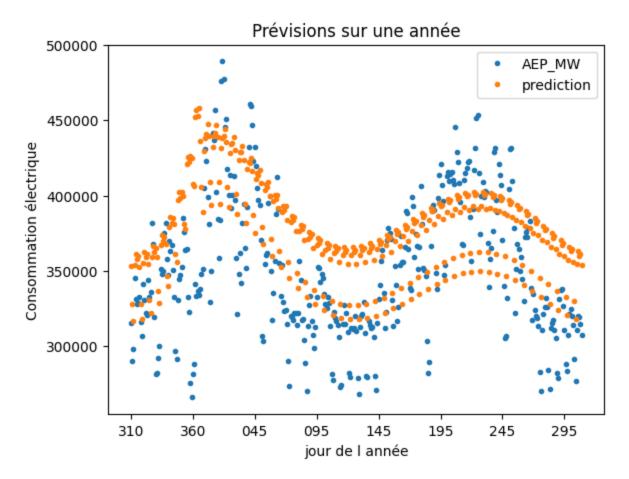
```
In [4]: # plot des résulats
  test_predictions_p.plot(x='day_of_year',y=['AEP_MW','prediction'],marker='."
```

Out[4]: <AxesSubplot:xlabel='jour de l année', ylabel='Consommation électrique'>



In [5]: # plot d'une année
 test\_predictions\_p.loc[(test\_predictions\_p.index>"2015-11-05") & (test\_predi

Out[5]: <AxesSubplot:title={'center':'Prévisions sur une année'}, xlabel='jour de l année', ylabel='Consommation électrique'>



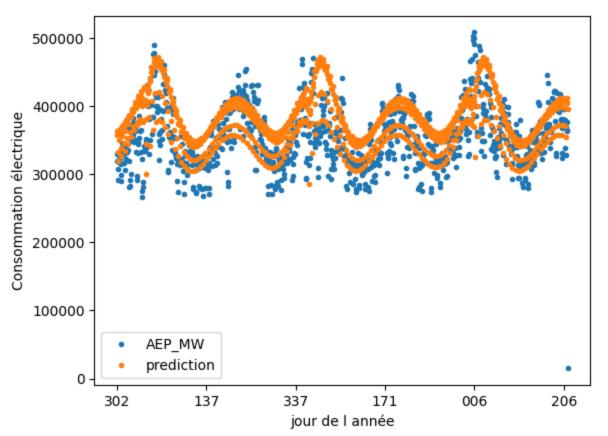
```
In [6]: #évaluation des prédictions
    print("RMSE %s" %mean_squared_error(test_predictions_p["AEP_MW"],test_predic
    print("MSE %s" %mean_absolute_error(test_predictions_p["AEP_MW"],test_predic
    RMSE 43975.71164713449
    MSE 34961.37300042017
```

### Comparaison avec un degré suplémentaire

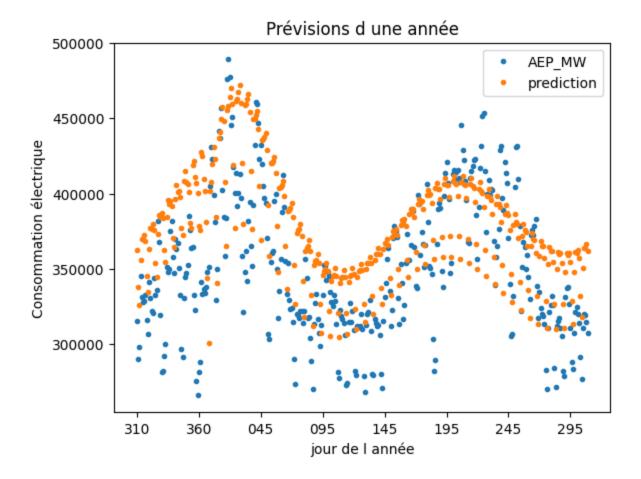
#### Affichage des prédictions

```
In [8]: # plot des prédictions
test_predictions_pbis.plot(x='day_of_year',y=['AEP_MW','prediction'],marker=
```

Out[8]: <AxesSubplot:xlabel='jour de l année', ylabel='Consommation électrique'>



In [9]: #plot d'une année
 test\_predictions\_pbis.loc[(test\_predictions\_pbis.index>"2015-11-05") & (test



### Evaluation des prédictions avec un degré 6

```
In [10]: #pres
    print("RMSE %s" %mean_squared_error(test_predictions_pbis["AEP_MW"],test_pre
    print("MSE %s" %mean_absolute_error(test_predictions_pbis["AEP_MW"],test_pre

RMSE 1999409550.2536457
MSE 35070.344371712876
```

Nous avons affaire ici à un sur-apprentissage: à un degré supplémentaire l'algorithme surapprends sur les particularités de chaque donnée, et donc ses prédictions sont moins précises